

FORECASTING BITCOIN VOLATILITY USING LSTM AND GARCH

1.Aboosaleh Mohammad Sharifi

Ph.D. Candidate, Information technology
management Department, Tehran North Branch,
Islamic Azad University, Tehran, Iran
sharifi.absh@gmail.com

2. Alireza hashemi

Abstract

Recently, Bitcoin as the most popular cryptocurrency, has attracted the attention of many investors and economic actors. The cryptocurrency market has experienced a sharp fluctuation, and one of the challenges is to predict future prices. Undoubtedly, creating methods to predict the price of bitcoin is very exciting and has a huge impact on determining the profit and loss from its trading in the future. in this study in order to predict the real volatility of Bitcoin from different statistical models and machine learning, including recurrent neural network LSTM and GARCH-GJR, GARCH and TARCH have been used. The main goal of this research is to determine the impact of deep learning models on the function of predicting the future volatility of Bitcoin and comparing it with other models. The results show that the proposed model - MultiVariate-Bidirectional-2layer LSTM has performed better in the evaluation criteria such as RMSE and MAPE than other models in predicting bitcoin fluctuations.

Keywords: Price Prediction, Cryptocurrency, Bitcoin, Deep Learning, Recurrent neural network, Long short-term memory.

چکیده

اخیراً بیت کوین به عنوان محبوب ترین رمزارز، مورد توجه بسیاری از سرمایه گذاران و فعالان اقتصادی قرار گرفته است. بازار رمز ارزها نوسان به شدت زیادی را تجربه کرده است و یکی از چالش های پیش روی آن، پیش بینی قیمت و نوسان آینده است. بدون شک، ایجاد روش هایی برای پیش بینی نوسان بیت کوین بسیار هیجان انگیز بوده و تأثیر بسیار زیادی در تعیین سود و زیان حاصل از معامله آن در آینده دارد. در این پژوهش به منظور پیش بینی نوسانات واقعی بیت کوین از مدل های مختلف ریاضی-آماري و یادگیری ماشینی اعم از شبکه عصبی بازگشتی LSTM و GARCH, GJR-GARCH و TARCH استفاده شده است. هدف اصلی این پژوهش تعیین تأثیر مدل های یادگیری عمیق بر روی عملکرد پیش بینی نوسانات آینده بیت کوین و مقایسه آن با سایر مدل ها است. نتایج بدست آمده نشان می دهد مدل پیشنهادی Multi-variate-Bidirectional-2layer-LSTM در معیار های ارزیابی نسبت به سایر مدل ها عملکرد بهتری در پیش بینی نوسانات بیت کوین داشته است.

کلیدواژه ها: پیش بینی قیمت، رمز ارز، بیت کوین، یادگیری عمیق، میانگین متحرک خود همبسته یکپارچه، شبکه عصبی بازگشتی، حافظه طولانی -کوتاه مدت.

۱:مقدمه

رمز ارزها^۱ ابزارهای جدید مالی هستند که از ویژگی های خاص و نوآورانه ای برخوردارند. هیچ دولت یا قدرت مرکزی آنها را تولید نکرده و کنترل نمی کند و هیچ بهره و سودی از آن ندارند، اما هر روز به شهرت آنها افزوده میشود. بیت کوین به عنوان پدر رمز ارزها و از محبوب ترین آنها در بازار شناخته میشود. از سال ۲۰۰۹ دنیای معاملات مالی شاهد خیزش بیت کوین^۲ همراه با شیفتگی در بازار و در بسیاری از موارد شک و تردید بوده است. به دلیل عدم وابستگی، امروزه بیت کوین به عنوان یک ارز قابل سرمایه گذاری آسان مطرح بوده و علاقه مندان زیادی را به سوی خود جذب نموده است. بیت کوین در یک کیف پول دیجیتال ذخیره شده که اساساً مانند یک حساب بانکی مجازی است. تمامی تراکنش های

¹ Cryptocurrencies

² Bitcoin

معاملاتی آن بر روی یک زنجیره اطلاعاتی بنام "زنجیره بلوکی"¹ ذخیره میشود. هر رکورد در این زنجیره رمزنگاری شده و در طول معاملات، نام کاربری و مشخصات مالک پنهان میماند و فقط شناسه کیف پول بصورت عمومی نشان داده شامل زنجیره ای از بلوک میشود. بیت کوین از طریق یک شبکه همتا به همتا² شامل زنجیره ای از بلوک های زمانی کنترل میشود. هر بلوک، لیستی از اطلاعات تراکنش ها را داراست و در آن همه اعضا با هم برابرند و هیچ سرور مرکزی وجود ندارد که تعیین نماید چه کاری باید صورت پذیرد(بونو و همکاران ۲۰۱۵)

ناپایداری و ناکارآمدی نسبی بازارهای مالی و اوراق بهادار نسبت به حجم معاملات بزرگ موجب شده است که معاملات بیت کوین مستعد نوسانات بزرگی نسبت به سایر دارایی ها شود. از سوی دیگر خصوصیات بیت کوین آن را با پول نقد که توسط دولت ها حمایت میشود متفاوت نموده است. ارزش ارزهای دولتی وابسته به فعالیت بسیار متمرکز و تحت نظارت بانک های مرکزی کشورهاست. اما ارزش یک بیت کوین به آنچه سرمایه گذاران حاضر به پرداخت آن در همان لحظه معامله هستند، کاملاً وابسته است. از این رو علاقه مندان به سرمایه گذاری به دلیل دریافت سود بیشتر به سمت بیت کوین در حرکت هستند(پویسر ۲۰۱۹)

از سوی دیگر قیمت یک دارایی به عنوان عامل اصلی در معاملات بازارهای اوراق بهادار مطرح است. بازارهای مالی توسط مشارکت کنندگان آن، بر اساس روابط عرضه و تقاضا میتوانند ارزش واقعی یک دارایی را تنظیم نمایند. برای قیمت بیت کوین سه عامل مطرح است. عرضه و تقاضا از عوامل اصلی داخلی است که تاثیر مستقیمی بر قیمت بازار آن دارد و از سوی دیگر جذابیت و محبوبیت، قانونی سازی و عوامل کلان مانند نرخ بهره، بازار سهام، قیمت طلا میتواند به عنوان عوامل خارجی تاثیرگذار بر قیمت بیت کوین باشند(سووتف ۲۰۱۸)

با این حال برای حضور پر قدرت در این بازار و به تبع آن کسب سود بیشتر، استراتژی مناسب برای پیش بینی قیمت، میتواند تعیین کننده سود و زیان حاصل از معامله در آینده باشد. این استراتژی میتواند خطر معامله را کاهش داده و همچنین فرصت های فراوانی را برای مشارکت کنندگان آن ایجاد نماید. پیش بینی آینده، عمدتاً به دلیل تغییرات بی سابقه در روندها و شرایط اقتصادی از یک سو و اطلاعات ناقص از طرف دیگر یک چالش بزرگ است. نوسانات بازار در سال های اخیر نگرانی های جدی را برای پیش بینی های اقتصادی و مالی ایجاد کرده است. بنابراین، هنگام استفاده از روش های مختلف پیش بینی، ارزیابی میزان صحت و دقت آنها برای تعیین استراتژی مناسب ضروری است. بررسی پژوهش های پیشین حاکی از این است که در سال های اخیر برای پیش بینی سری های زمانی از دو گروه عمده از مدل ها استفاده شده است. گروه اول مبتنی بر مدل های ریاضی سنتی هستند که از جمله آنها میتوان به روش میانگین متحرک خود همبسته یکپارچه³، مدل فیلتر کالمن⁴ و ... اشاره نمود. با وجود اینکه، این روش ها در زمینه پیش

¹ Block Chain

² Peer-to-peer

³ Auto Regressive Integrated Moving Average (ARIMA)

⁴ Kalman filter

بینی سری های زمانی عملکرد نسبی خوبی داشته اند، اما برای تصمیم گیری نهایی، به تنهایی کافی نیستند. از سوی دیگر، روش های یادگیری ماشین¹، رویکردهای جدیدی را برای حل مشکلات پیش بینی معرفی کرده اند که در آن روابط بین متغیرها در یک سلسله مراتب عمیق و لایه بندی شده مدل می شوند. این روش ها مانند شبکه های عصبی مصنوعی، ماشین های بردار پشتیبان²، جنگل های تصادفی³ و مدل های یادگیری عمیق⁴ مانند شبکه عصبی بازگشتی⁵ و حافظه طولانی کوتاه-مدت⁶ اخیرا مورد توجه پژوهشگران حوزه های پیش بینی قرار گرفته اند (مک نالی ۲۰۱۸)

با وجود اینکه هر یک از این روش ها به موفقیت هایی در پیش بینی سری های زمانی دست یافته اند، اما هیچ کدام از آنها یک مدل عمومی و مناسب برای تمامی شرایط نیستند زیرا مدل های آماری سنتی برای مسائل غیرخطی پیچیده مناسب نیستند و به کارگیری شبکه های عصبی برای مسائل خطی نتایج مختلفی را نشان میدهد. در این پژوهش سعی شده عملکرد و رویکرد برخی از مدل های ریاضی سنتی و رویکرد های نوین مثل شبکه های عصبی بازگشتی بر روی داده های تاریخی بیتکوین بررسی و ارزیابی و مقایسه شوند. هدف، یافتن بهترین نوع شبکه عصبی عمیق و بررسی کارایی عملکرد آن بر روی داده های بیت کوین است. مقاله به شرح زیر سازماندهی میشود. در بخش دوم، مبانی نظری و جدیدترین مطالعات مرتبط با رویکردهای پیش بینی قیمت بیت کوین را بیان میشود. بخش سوم مدل پیشنهادی را تشریح و در ادامه در بخش چهارم، مراحل اجرای مدل و نتایج حاصل از ارزیابی عملکرد بر روی داده ها بیان میشود. سرانجام، نتیجه گیری در بخش پنجم ارائه میگردد

۲: مبانی نظری

شبکه عصبی بازگشتی

یک شبکه عصبی بازگشتی شامل سه لایه ورودی، پنهان و خروجی است. همانطور که در شکل ۱ مشاهده میشود، مجموعه ورودی با بردار x و مجموعه پنهان با بردار h و مجموعه خروجی با بردار y مشخص می شود.

¹ Machine Learning


² Support vector machine

³ Random forest

⁴ Deep Learning

⁵ Recurrent neural network(RNN)

⁶ Long short-term memory(LSTM)



شکل ۱. ساختار شبکه عصبی بازگشتی

ساختار شبکه عصبی بازگشتی شامل یک حلقه بازگشتی است، که کمک مینماید اطلاعات کسب شده از زمان های قبلی حذف نشده و در شبکه باقی بمانند. در مقایسه با یک شبکه عصبی پیشخور^۱، شبکه عصبی بازگشتی میتواند دنباله طولانی از داده هارا پردازش کند.

در هر مرحله زمانی t حالت مخفی h_t براساس معادله زیر بروزرسانی می شود (مک نالی و همکاران، ۲۰۱۸)

$$h_t = f(W h_{t-1} + U x_t)$$

در این معادله، f یک تابع فعال سازی غیرخطی مانند تابع سیگموئید^۲ است. W ماتریسی است که با لایه مخفی فعلی و لایه پنهان قبلی مرتبط است و U ماتریسی است که با لایه ورودی فعلی و لایه پنهان فعلی مرتبط است. در هر مرحله زمانی t ، خروجی y_t با تابع زیر به روز میشود که در آن V ماتریسی است که با لایه پنهان فعلی و لایه خروجی فعلی مرتبط شده است.

$$y_t = f(V h_t)$$

وقتی صحبت از دنباله طولانی است، آموزش این نوع از شبکه عصبی دشوار خواهد بود. به دلیل ساختار خاص، مشکل گرادیان ناپدید شده^۳ در ورودی برای دنباله طولانی بوجود می آید. در این حالت شبکه عصبی بازگشتی فقط میتواند آخرین اطلاعات را به خاطر بسپارد و اطلاعات قبل از آن را به خاطر نمی آورد.

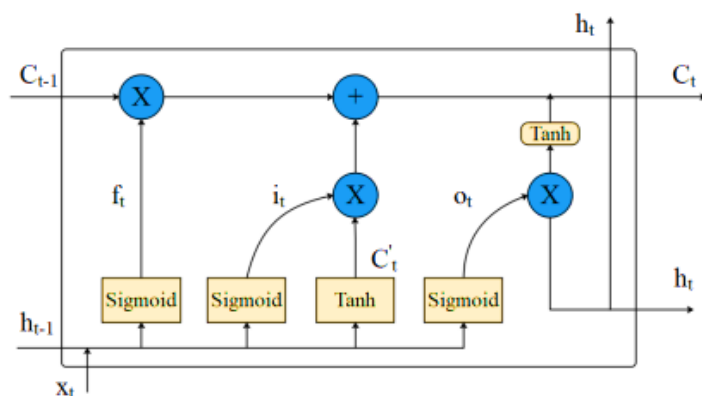
¹ Feedforward Neural Network

² Sigmoid function

³ vanishing gradient

حافظه طولانی کوتاه - مدت

حافظه طولانی کوتاه - مدت نوع خاصی از شبکه عصبی بازگشتی هستند که برای حل مشکل شبکه های عصبی بازگشتی و یادگیری وابستگی های طولانی مدت طراحی شده اند. از آنجا که این نوع شبکه روی طیف گسترده ای از مشکلات به خوبی کار میکند، امروزه به طور گسترده مورد استفاده پژوهشگران حوزه های مختلف قرار گرفته است.



شکل ۲. ساختار شبکه عصبی بازگشتی حافظه طولانی-کوتاه مدت

نمودار ساختار این نوع شبکه عصبی در شکل ۲ نشان داده شده است. سلول حافظه G شامل سه دروازه ورودی^۱، فراموشی^۲ و خروجی^۳ است که برای محافظت و به روزرسانی وضعیت سلول طراحی شده است. با استفاده از این دروازه ها، شبکه حافظه طولانی کوتاه - مدت توانایی حذف یا افزودن اطلاعات به سلول را دارد (رشید و همکاران ۲۰۱۸) با توجه به رابطه زیر دروازه ی فراموشی F_t وظیفه کنترل جریان اطلاعات از گام زمانی قبلی را دارد و مشخص میکند که کدام اطلاعات از حافظه حذف شوند.

$$f_t = \sigma(WF h_t - 1 + UF x_t - 1)$$

¹ Input gate

² Forget gate

³ Output gate

در مرحله بعد، اطلاعات جدید باید به طور مشروط در سلول ذخیره شود. یک لایه تانژانت هایپربولیک^۱ برای شکل دادن به حافظه جدید انتخاب میشود (رابطه ۵) و دروازه ورودی I_t وظیفه کنترل جریان اطلاعات جدید را بر عهده گرفته و اطلاعات قابل افزوده شدن به حافظه را بر اساس رابطه (۶) مشخص میکند.

$$G_t = \tanh(WG_{ht-1} + UG_{xt-1})$$

$$I_t = \sigma(WI_{ht-1} + UI_{xt-1})$$

سپس، بر اساس رابطه (۷) وضعیت سلول، توسط دروازه فراموشی، ورودی و حافظه جدید به روز میشود.

$$S_t = S_{t-1} \times F_t + G_t \times I_t$$

در نهایت، در رابطه (۸) و (۹) دروازه ی خروجی O_t مشخص میکند چه میزان از اطلاعات گام زمانی قبل با اطلاعات گام زمانی فعلی به گام زمانی بعدی منتقل شود.

$$O_t = \sigma(WO_{ht-1} + UO_{xt-1})$$

$$h_t = O_t \times \tanh(S_t)$$


در معادلات بالا WO, WG, WF, WI مقادیر وزن بین لایه پنهان فعلی و لایه پنهان قبلی و UO, UG, UF, UI مقادیر وزنی بین لایه ورودی فعلی و لایه پنهان فعلی را نشان می دهد.

مدل واریانس ناهمسانی شرطی خود رگرسیونی^۲:

در سال ۱۹۸۲ اقتصادسنجی به نام رابرت انگل در مطالعه روند داده های تورم، دریافت که در تورم های بالا، نوسانات بیشتر و در تورم های پائین، نوسانات کمتر است. به عبارت دیگر، تغییرات بزرگ در متغیر مورد نظر، منجر به تغییرات بزرگ و تغییرات کوچک، منجر به تغییرات کوچک میشود.

^۱ hyperbolic tangent

^۲ Autoregressive Conditional Heteroskedasticity (ARCH)



شکل ۳. نوسان پذیری خوشه ای در داده های سری زمانی

در واقع انگل با تمایز گذاشتن بین واریانس شرطی و غیرشرطی^۱، فصل جدیدی را در کاراتر ساختن تخمین ضرایب و بهبود نتایج پیشبینی کرد.

حال برای مدلسازی نوسان پذیری خوشه ای و یا واریانس شرطی اجزاء خطا از رابطه زیر استفاده میشود:

$$\sigma_t^2 = \text{var}(u_t | u_{t-1}, u_{t-2}, \dots) = E[(u_t - E(u_t))^2 | u_{t-1}, u_{t-2}, \dots]$$

که با فرض $E(u_t) = 0$ داریم:

$$\sigma_t^2 = E(u_t^2 | u_{t-1}, u_{t-2}, \dots)$$

بر اساس رابطه فوق، واریانس شرطی u_t برابر است با امید ریاضی شرطی مجذور u_t . لذا محاسبه واریانس جزء خطا در زمان t ، به شرط معلوم بودن مقادیر خطا در دوره های گذشته امکان پذیر خواهد بود.

رابطه زیر، مدل ARCH را که در ساده ترین حالت، تنها به مجذور جمله خطا در دوره قبل بستگی دارد نشان می دهد که تحت عنوان ARCH(1) شناخته می شود.^۲

^۱. بحث هایی که در اقتصاد سنجی کلاسیک در خصوص واریانس ناهمسانی مطرح میشود، مربوط به واریانس غیرشرطی است و نه واریانس شرطی.

در برخی از کتب و مقالات به جای استفاده از معادله واریانس در رابطه فوق از دو رابطه زیر استفاده میکنند: ^۲.

$$u_t = v_t \sigma_t \quad ; \quad v_t \sim N(0,1)$$

$$\sigma_t^2 = \alpha_0 + \alpha_1 u_{t-1}^2$$

$$\sigma_t^2 = \alpha_0 + \alpha_1 u_{t-1}^2$$

معادله فوق به معادله واریانس معروف^۱ است که مطابق معمول میتوان آن را تا وقفه دلخواه گسترش داد. لذا در نهایت برای ارائه برآوردهای بهتر از ضرایب و همچنین پیشبینی های دقیقتر، بایستی دو معادله میانگین و واریانس به طور همزمان برآورد گردند. لذا چنانچه رابطه 4 را تا وقفه q ام گسترش دهیم، مدل ARCH(q) به صورت زیر خواهد بود:

$$Y_t = a_0 + \sum_{l=1}^m a_l Y_{t-l} + u_t - \sum_{h=1}^n b_h u_{t-h} \quad ; \quad u_t \sim N(0, \sigma_t^2)$$

$$\sigma_t^2 = \alpha_0 + \sum_{i=1}^q \alpha_i u_{t-i}^2 \quad ; \quad \alpha_0 > 0, \alpha_i \geq 0$$

مدل واریانس ناهمسانی شرطی خودرگرسیوني تعمیم یافته^۲:

مدل ARCH دارای دو نقطه ضعف اساسی است؛ اول اینکه تعیین مقدار q (وقفه های معادله واریانس) بسیار دشوار بوده و دوم اینکه برای جلوگیری از منفی شدن مقادیر برآورد شده واریانس، نیاز است که ساختار خاص و از پیش تعیین شده ای بر مدل اعمال گردد. برای رفع این مشکلات، اقتصادسنجی به نام بولر سلف^۳ در سال ۱۹۸۶ مدل ARCH تعمیم یافته یا GARCH را ارائه کرد. این مدل دارای معادله میانگین به شکل مرسوم ولی معادله واریانس متفاوت از مدل ARCH است که شکل ساده آن به صورت زیر است:

$$\sigma_t^2 = \alpha_0 + \alpha_1 u_{t-1}^2 + \beta \sigma_{t-1}^2$$

رابطه فوق با GARCH(1,1) نشان داده می شود. به راحتی می توان نشان داد که معادله فوق معادل است با ARCH(∞). برای این منظور با نوشتن رابطه فوق با یک وقفه جایگذاری آن در رابطه فوق داریم:

$$\begin{aligned} \sigma_t^2 &= \alpha_0 + \alpha_1 u_{t-1}^2 + \beta (\alpha_0 + \alpha_1 u_{t-2}^2 + \beta \sigma_{t-2}^2) \\ &= \alpha_0 (1 + \beta) + \alpha_1 u_{t-1}^2 + \beta \alpha_1 u_{t-2}^2 + \beta^2 \sigma_{t-2}^2 \end{aligned}$$

به طور مشابه، با جایگذاری های مکرر خواهیم داشت:

¹ . Variance Equation

² . Generalized Autoregressive Conditional Heteroskedasticity (GARCH)

³ . Bollerslev

$$\sigma_t^2 = \alpha_0(1 + \beta + \beta^2 + \dots) + \alpha_1(u_{t-1}^2 + \beta u_{t-2}^2 + \beta^2 u_{t-3}^2 + \dots)$$

$$= \alpha'_0 + \alpha'_1 u_{t-1}^2 + \alpha'_2 u_{t-2}^2 + \alpha'_3 u_{t-3}^2 + \dots ; \quad \alpha'_0 = \alpha_0 \sum_{i=0}^{\infty} \beta^i, \alpha'_i = \alpha_i \beta^i$$

بنابراین GARCH(1,1) معادل ARCH(∞) خواهد بود. اما در حالت کلی، مدل GARCH(q,p) به صورت زیر تعریف می شود.

$$Y_t = a_0 + \sum_{i=1}^m a_i Y_{t-i} + u_t - \sum_{h=1}^n b_h u_{t-h} ; \quad u_t \sim N(0, \sigma_t^2)$$

$$\sigma_t^2 = \alpha_0 + \sum_{i=1}^q \alpha_i u_{t-i}^2 + \sum_{j=1}^p \beta_j \sigma_{t-j}^2 ; \quad \alpha_0 > 0, \alpha_i, \beta_j \geq 0$$

اما با این وجود، نتایج بیشتر مطالعات تجربی، بر کفایت GARCH(1,1) تاکید دارند.

مدل واریانس ناهمسانی شرطی آستانه ای^۱:

در مدل هایی که تاکنون بررسی شد، اثر شوک های مثبت و منفی بر معادله واریانس، یکسان و متقارن در نظر گرفته شده است. اما به طور معمول انتظار داریم اثر شوک های مثبت و منفی که به بازدهی سهام وارد میشود و یا اثر کاهش و افزایش قیمت نفت بر اقتصاد متفاوت از یکدیگر عمل کنند. برای این منظور، یکی از مدل هایی که برای در نظر گرفتن چنین عدم تقارنی در اخبار و اطلاعات وارده بر بازارهای مالی و سطح کلان اقتصاد در نظر گرفته شده است، مدل ARCH آستانه ای یا TARCH است. در واقع مدل TARCH به دنبال تبیین اثرات وقایعی است که در گذشته روی داده است ولی اثر آنها در زمان حال ظاهر میشود. این مدل نیز دارای معادله میانگین به شکل قبل، ولی معادله واریانس به شکل رابطه زیر است:

$$\sigma_t^2 = \alpha_0 + \sum_{i=1}^q \alpha_i u_{t-i}^2 + \sum_{j=1}^p \beta_j \sigma_{t-j}^2 + \sum_{i=1}^r \gamma_i u_{t-i}^2 I_{t-i}$$

$$\begin{cases} I_{t-i} = 1 & ; \quad u_{t-i} < 0 \\ I_{t-i} = 0 & ; \quad u_{t-i} \geq 0 \end{cases}$$

در این مدل $u_{t-1} \geq 0$ بیانگر اخبار خوب و $u_{t-1} < 0$ بیانگر اخبار بد میباشد. همچنین در این مدل، مقدار r بیانگر تعداد وقفه هایی است که طی آن، اخبار گذشته (خوب یا بد) بر واریانس اثر میگذارند. در این مدل تأثیر اخبار خوب به میزان α_i

¹ Threshold ARCH (TARCH)

و تاثیر اخبار بد به میزان $\alpha_i + \gamma_i$ است. از سوی دیگر، به راحتی میتوان دریافت که چنانچه ضرایب γ_i به ازای $i = 1, 2, \dots, r$ معنی دار نباشند، مدل متقارن خواهد بود. همچنین چنانچه $\gamma_i > 0$ باشد، اثر شوک های منفی بیشتر از اثر شوک های مثبت در دوره i ام بوده است و بالعکس.

۲،۱: پیشینه پژوهش

بررسی مطالعات های صورت گرفته نشان میدهد، پژوهشهای اندکی در مورد برآورد یا پیش بینی قیمت بیت کوین انجام شده است. از آن جمله میتوان به موارد زیر اشاره نمود. صالحی فر (۱۳۹۸)، در پژوهشی با استفاده از آزمون ریشه واحد دیکی-فولر مدل تک متغیره TGARCH، GJR- GARCH و ضریب همبستگی اسپیرمن بازدهی و ریسک معاملات بیت کوین در مقایسه با سایر بازارهای رقیب مانند ارز (دلار و یورو)، بورس و طلا (قراردادهای آتی طلا و سکه بهار آزادی) را بررسی کرده است. اگرچه نتایج نشان میدهد بازده و ریسک بیت کوین نسبت به سایر فرصتهای سرمایه گذاری مانند ارز، طلا، سکه و بورس در داخل کشور به طور قابل ملاحظه ای بیشتر است اما بدلیل ویژگی های متفاوت ریسک و بازده منحصر به فرد در بیت کوین، نمی توان آن را با سایر داراییها مقایسه نمود و رفتار آن را از نظر ریسک و بازدهی با بازارهای رقیب مرتبط دانست

دووتا و همکاران (۲۰۲۰) یک چارچوب جدید با استفاده از مجموعه ای از روشهای پیشرفته پیش بینی یادگیری ماشین برای پیش بینی قیمت روزانه بیت کوین پیشنهاد نمودند. نتایج آنها نشان میدهد مدل های شبکه های عصبی بازگشتی نسبت به مدل های سنتی یادگیری ماشین دارای عملکرد بهتر هستند و معماری شبکه عصبی واحد بازگشتی دروازه ای در تجزیه و تحلیل داده ها عملکرد بهتری از حافظه طولانی کوتاه - مدت نشان میدهد. آلباریکی و وینارکو (۲۰۲۰) برای پیش بینی تغییرات کوتاه مدت و بلند مدت قیمت بیت کوین از شبکه های عصبی پرسپترون چند لایه و بازگشتی استفاده نمودند. آنها با بررسی ۱۳۰۰ نمونه از داده های بیت کوین نشان دادند که مدل آنها در پیش بینی بلند مدت نسبت به کوتاه مدت دقیقتر عمل میکند. نتایج پژوهش نشان میدهد مدل شبکه عصبی پرسپترون چند لایه در بازه زمانی بلند مدت (۶۰ روز) دارای دقت ۸۱،۳ درصدی و شبکه عصبی بازگشتی در بازه ۵۶ روزه دارای دقت ۷۷،۳ درصدی است.

یاماک و همکاران (۲۰۱۹) در پژوهشی، عملکرد مدل های مختلف یادگیری عمیق را به همراه مدل میانگین متحرک خود همبسته یکپارچه برای پیش بینی داده های بیت کوین مقایسه نمودند. آنها از شبکه عصبی عمیق حافظه طولانی کوتاه - مدت و واحد بازگشتی دروازه ای برای مقایسه با مدل سنتی استفاده نمودند. نتایج آنها نشان میدهد مدل میانگین متحرک خود همبسته یکپارچه در مقایسه با شبکه عصبی عمیق نتایج بهتری را نشان میدهد. از سوی دیگر پژوهش آنها نشان میدهد مدل واحد بازگشتی دروازه ای نسبت به مدل حافظه طولانی کوتاه - مدت دارای عملکرد

بهتری است. کاراکویون و سیبیل دیکن (۲۰۱۸)، به مقایسه مدل سری زمانی میانگین متحرک خود همبسته یکپارچه با حافظه طولانی کوتاه - مدت در پیش بینی قیمت بیت کوین پرداختند. آنها برای ارزیابی مدل از شاخص ارزیابی خطای MAPE استفاده نمودند. مطالعه آنها نشان داد مدل حافظه طولانی کوتاه - مدت در مقایسه با میانگین متحرک خود همبسته یکپارچه دارای عملکرد بهتری بود. نتایج به دست آمده حاکی از مقدار MAPE حدوداً ۱۱,۸۶ درصدی برای میانگین متحرک خود همبسته یکپارچه و مقدار تقریباً ۱,۴۰ درصدی برای حافظه طولانی کوتاه - مدت بود. مک نالی (۲۰۱۸)، در پژوهشی برای پیش بینی فرآیند قیمت بیت کوین، شبکه های عصبی بازگشتی و حافظه طولانی کوتاه - مدت را استفاده نموده و در نهایت نتایج حاصله را با مدل میانگین متحرک خود همبسته یکپارچه مقایسه نمود. نتایج پژوهش آنها نشان داد، حافظه طولانی کوتاه - مدت در مقایسه با دو مدل دیگر دارای عملکرد بهتر در هر دو معیار دقت و کاهش خطا بود. ژیونگ و لو (۲۰۱۷)، مدل میانگین متحرک خود همبسته یکپارچه را با شبکه عصبی پس انتشار ترکیب و برای پیش بینی در بازار سرمایه پیاده سازی نمودند. نتایج آزمایش آنها نشان داد که روش پیشنهادی دارای دقت 78.79 درصد بوده و نسبت به مدل غیر ترکیبی دارای دقت بالاتری است. کاتسیامپا (۲۰۱۷) در مطالعه ای با بررسی انواع مدل های GARCH بر روی داده های بیت کوین بهترین مدل آن را گزارش مینماید. نتایج نشان میدهد مدل AR-CGARCH برای پیشبینی اطلاعات قیمت بیت کوین مدل مناسب تری بوده است.

سین و وانگ (۲۰۱۷)، با در نظر گرفتن رابطه بین ویژگی های بیت کوین و تغییرات قیمت روز بعد آن، مدلی ترکیبی بر پایه شبکه عصبی پرسپترون چند لایه و الگوریتم ژنتیک ارائه نمودند. آنها برای درک بهتر اثربخشی و کاربرد آن در دنیای واقعی، از مدل ترکیبی برای پیش بینی قیمت بیت کوین در روز بعد استفاده نمودند. نتایج آنها نشان داد، در بازه زمانی ۵۰ روز، یک استراتژی معاملاتی مبتنی بر مدل ترکیبی در برابر یک استراتژی معاملاتی مبتنی بر قیمت روز قبل، بازده ۸۵ درصدی را نشان میدهد. این درحالیست که استراتژی معاملاتی مبتنی بر قیمت روز قبل تنها ۳۸ درصد بازده ایجاد کرده است. گریوز و او (۲۰۱۵)، شبکه بلاک چین بیت کوین را تجزیه و تحلیل نمودند تا قیمت بیت کوین را با استفاده ماشین بردار پشتیبان و شبکه عصبی مصنوعی پیش بینی نمایند. نتایج آنها دقت ۵۵ درصدی در شبکه عصبی مصنوعی برای پیش بینی و تعیین مسیر تغییر قیمت ها را نشان میدهد. مادان و همکاران (۲۰۱۵)، با بررسی ویژگی های شبکه بیت کوین، قیمت آن را بر اساس داده های تاریخی در بازه های ۳۰، ۶۰ و ۱۲۰ دقیقه تحلیل نمودند. آنها با استفاده از الگوریتم های جنگل تصادفی، ماشین بردار پشتیبان و رگرسیون لجستیک دوجانبه، وضعیت قیمت ۱۰ دقیقه آینده بیت کوین را با دقت تقریبی ۵۵ درصد پیش بینی نمودند.

۳: مدل پیشنهادی

LSTM دو جهته چند متغیره^۱ برای پیش بینی نوسانات بیت کوین

در این بخش، مدل پیشنهادی برای پیش‌بینی نوسانات بیت‌کوین را با استفاده از یک شبکه عصبی چند متغیره حافظه کوتاه‌مدت (LSTM) ارائه می‌کنیم. این مدل به گونه ای طراحی شده است که وابستگی های پیچیده در داده های تاریخی را به تصویر بکشد و پیش بینی های دقیق نوسانات را ارائه دهد.

۳،۱: معماری مدل

مدل پیشنهادی از یک شبکه LSTM دو جهته چند متغیره با دو لایه استفاده می‌کند که به طور استراتژیک طراحی شده‌اند تا پویایی‌های زمانی و وابستگی‌های متقابل درون داده‌های ورودی را به تصویر بکشند. این معماری به دلیل توانایی آن در مدل‌سازی مؤثر داده‌های متوالی و گرفتن هر دو زمینه گذشته و آینده به طور همزمان انتخاب شده است. لایه ورودی مدل به گونه ای پیکربندی شده است که پنجره ای از داده های گذشته را بپذیرد، با نرمال سازی دسته ای برای عادی سازی ویژگی های ورودی و بهبود همگرایی در طول آموزش اعمال می شود. اولین لایه LSTM دو جهته است که از ۳۲ واحد^۲ تشکیل شده است و برای پردازش توالی های ورودی در جهت جلو و عقب طراحی شده است. این ماهیت دوسویه به مدل اجازه می‌دهد تا وابستگی‌ها را از مراحل زمانی گذشته و آینده بگیرد و درک جامع‌تری از الگوهای اساسی در داده‌ها را ممکن می‌سازد.

به دنبال لایه LSTM دو طرفه، یک لایه انصراف با نرخ انصراف^۳ ۰٫۱ برای کاهش بیش از حد برازش و افزایش قابلیت های تعمیم مدل گنجانده شده است. متعاقباً، لایه دوم LSTM، همچنین دو طرفه با ۳۲ واحد، برای جذب بیشتر وابستگی‌های زمانی پیچیده در داده‌ها معرفی می‌شود. لایه انصرافی دیگری با نرخ ۰٫۱ از لایه دوم LSTM پیروی می‌کند که به منظم شدن مدل کمک می‌کند.

مؤلفه نهایی معماری پیشنهادی یک لایه خروجی متراکم است که مقادیر نوسانات پیش بینی شده را تولید می‌کند. این لایه برای ارائه یک خروجی منفرد مطابق با نوسانات پیش بینی شده طراحی شده است و اطلاعات آموخته شده توسط لایه های قبلی را در یک پیش بینی منسجم یکپارچه می‌کند.

^۱ Multi variate-Bidirectional LSTM

^۲ Unit

^۳ Dropout

منطق پشت این معماری در توانایی آن برای ثبت موثر پویایی های زمانی و وابستگی های پیچیده موجود در داده های سری زمانی چند متغیره نهفته است، در نتیجه پیش بینی نوسان دقیق برای بیت کوین را ممکن می سازد.

۳,۲: آموزش مدل

مدل پیشنهادی با استفاده از داده های تاریخی بیت کوین، با تاکید بر تکرارپذیری و استحکام آموزش داده شده است. برای دستیابی به این هدف، دانه تصادفی برای اطمینان از نتایج ثابت در طول دوره های مختلف تنظیم شده است که به تکرارپذیری یافته های تجربی کمک می کند.

در طول فرآیند آموزش، مدل به داده های آموزشی بیش از ۵۰۰ دوره برازش^۱ می شود و به آن امکان می دهد الگوهای اساسی موجود در داده های تاریخی را بیاموزد و با آن سازگار شود. تقسیم اعتبار ۲۰٪ برای ارزیابی عملکرد مدل بر روی داده های دیده نشده و جلوگیری از برازش بیش از حد^۳ در طول فرایند آموزش استفاده می شود. علاوه بر این، اندازه دسته ای^۴ ۱۶ برای تسهیل آموزش کارآمد در حین مدیریت موثر منابع محاسباتی استفاده می شود.

برای بهبود بیشتر فرآیند آموزش و جلوگیری از تطبیق بیش از حد، از تماس های برگشتی برای بازرسی مدل و توقف زود هنگام استفاده می شود. بهترین مدل بر اساس از دست دادن اعتبارسنجی ذخیره می شود و تضمین می کند که مدل نهایی الگوهای ضروری را در داده ها ثبت می کند.


در همین حال، توقف زود هنگام تماس برگشتی، از دست دادن اعتبارسنجی را نظارت می کند و در صورت عدم مشاهده بهبود در تعداد معینی از دوره ها، فرآیند آموزش را خاتمه می دهد، در نتیجه از تطبیق بیش از حد و ترویج تعمیم جلوگیری می کند. فرآیند آموزش دقیق و تماس های مربوطه برای اطمینان از اینکه مدل پیشنهادی به عملکرد بهینه دست می یابد و در عین حال قابلیت های استحکام و تعمیم را حفظ می کند، پیاده سازی می شوند.

¹ Epoch

² Validation

³ Overfitting

⁴ Batch-size



شکل ۴. ارزیابی فرایند آموزش مدل پیشنهادی در ۱۴۰ دوره برازش


۴ : پیاده سازی

۴,۱,۱ : داده ها و پیش پردازش

رمزارزها آخرین نوآوری‌های مالی هستند که می‌توانند به عنوان ریسک‌ها و فرصت‌های بالقوه در صنعت مالی مطرح شوند. صدها رمزارز با طرح‌های مختلف در بازار وجود دارند. بازار رمزارزها بر اساس سرمایه‌گذاری بازار رمزارزها تقسیم‌بندی می‌شود. به عنوان مثال، در ماه مه ۲۰۱۷، پنج رمزارز برتر از نظر سرمایه‌گذاری بازار بیت‌کوین، اتریوم، XRP، لایت‌کوین و NEM بودند. این فهرست به تدریج با افزایش تعداد سرمایه‌گذاران تغییر می‌کند. اما در ماه مه ۲۰۲۰، بیت‌کوین، اتریوم، تتر، اکس‌آرپی و بیت‌کوین کش در صدر سرمایه‌گذاری بازار بودند. سرمایه‌گذاری بالا در این بازار نشان می‌دهد که سرمایه‌گذاران به دنبال کسب سود بیشتر از رمزارزها هستند. بنابراین، درک وضعیت آینده بازار، با تحلیل دقیق و کشف ریسک‌ها و فرصت‌ها ضروری است. به طور دیگر، قیمت‌های بیت‌کوین عامل اصلی بازار رمزارزها هستند، به طوری که تنها تراکنش‌های بیت‌کوین در طول ۵ سال گذشته به نزدیک ۶۰ درصد در سال افزایش یافته است.

داده‌ها به بازه‌های زمانی کوچکتری تقسیم می‌شوند تا مدل آموزش داده شود. اندازه بازه توسط تعداد داده‌های نمونه داخل آن تعیین می‌شود و گام بازه توسط تعداد نمونه‌ها بین انتهای دو بازه متوالی مشخص می‌شود. فرآیند

پیش‌بینی برای هر بازه انجام می‌شود، بنابراین امکان شبیه‌سازی فرآیند پیش‌بینی در طول زمان وجود دارد. بخش زیادی از داده‌های متوالی در ابتدای هر بازه برای آموزش مدل در هر دوره پیش‌بینی اختصاص داده می‌شود و بخش کوچکتر باقی‌مانده برای آزمون مدل و محاسبه خطای پیش‌بینی استفاده می‌شود. به عبارت دیگر، ضرایب وزن‌دار محاسبه می‌شود و مدل شبکه عصبی از طریق داده‌های آموزش در هر دوره پیش‌بینی ساخته می‌شود و سپس عملکرد مدل توسط داده‌های آزمون ارزیابی می‌شود. این فرآیند در هر بازه تکرار می‌شود و خطای پیش‌بینی در هر بازه محاسبه و ثبت می‌شود.



شکل ۵. طول پنجره و پیش‌بینی تنظیمات طول

داده‌های تاریخی بیتکوین که پژوهش مبتنی بر آن می‌باشد، شامل ۳۳۳۶ رکورد روزانه از تاریخ ۲۰۱۴ تا ۲۰۲۴ است.


در مرحله اول میزان نوسانات واقعی بیتکوین را بر اساس بازده لگاریتمی روزانه محاسبه می‌کنیم، سپس با استفاده از رویکرد پنجره چرخشی نوسانات متحول شده به عقب و آینده نگر را محاسبه می‌کنیم. طول پنجره چرخشی ۳۰ و تعداد روزهای آینده برای محاسبه تحقق یافته آینده نگر را ۷ در نظر گرفتیم.

داده به یک مجموعه آموزش با نرخ ۸۰٪ و یک مجموعه آزمایش با نرخ ۲۰٪ تقسیم می‌شود. نوسانات واقعی روزانه به عنوان ورودی برای مدل‌های پایه، GARCH, GJR-GARCH و همینطور Bootstrap-TARCH استفاده شده است.

سپس برای نرمال سازی^۱ داده‌های واقعی با استفاده از MinMaxScaler مقیاس داده شده و برای هر دو مجموعه آموزش و آزمایش تبدیل می‌شود.

$$X_{\text{new}} = \frac{X_i - \min(X)}{\max(x) - \min(X)}$$

¹ Normalize



شکل ۶. وضعیت داده های آموزش و آزمایش نرمال سازی شده -میزان بازده لگاریتمی روزانه

۴، ۱، ۲: مهندسی ویژگی^۱

ورودی های شبکه عصبی بازگشتی کوتاه-بلند مدت چند متغیره دو طرفه ما شامل لگاریتم طبیعی اختلاف بین بالا ترین قیمت و پایین ترین قیمت، اختلاف بین قیمت بسته شده و قیمت باز شده ، همچنین حجم روزانه میباشد. هر یک از این ویژگی ها نقش مهمی در تحلیل مالی دارند و می توانند به عنوان نشانگرهای نوسانات بازار، جهت بازار، و همچنین تقویت دقت مدل های یادگیری ماشین در پیش بینی حرکت قیمت بیتکوین، استفاده شوند. این ویژگی های جدید دقت پیش بینی حرکت قیمت و نوسانات بیتکوین را بهبود بخشند.

¹ Feature engineering

۴,۲ : شاخص های ارزیابی^۱

برای اندازه گیری عملکرد و نشان دادن میزان تاثیر پیش بینی هر مدل، از سه معیار مجذور میانگین مربعات خطا^۲ (RMSE) و میانگین قدرمطلق درصد خطا^۳ (MAPE) همینطور از مجذور میانگین مربعات خطا (RMSPE) استفاده میشود.

RMSE به انحراف بزرگ بین مقدار پیش بینی شده و مقدار واقعی حساس است، که میتواند صحت نتیجه پیش بینی را به خوبی منعکس کند. MAPE. انحراف بین مقدار پیش بینی شده و مقدار واقعی و همچنین رابطه بین خطا و مقدار واقعی را در نظر میگیرد، که میتواند بهتر نتیجه پیش بینی کند. RMSPE نسبت به مقادیر واقعی استاندارد معمول تری برای ارزیابی دقت پیش بینی هاست. این شاخص برای مواردی که مقادیر واقعی و پیش بینی شده نسبت به هم متفاوت اند، مناسب است و به خوبی نشان می دهد که مدل چقدر خطا دارد. معادلات مربوطه به شرح زیر است:

$$RMSE = \sqrt{\frac{1}{N} \sum_{t=1}^N (x_t - \hat{x}_t)^2}$$

$$MAPE = \frac{100}{N} \sum_{t=1}^N \left| \frac{x_t - \hat{x}_t}{x_t} \right|$$

$$RMSPE(Y_i, \hat{Y}_i) = \sqrt{\frac{100}{n} * \sum_{i=1}^n \left(\frac{|Y_i - \hat{Y}_i|}{|Y_i|} \right)^2}$$

4.3 : تعیین پارامتر^۴

با توجه به موارد مطرح شده مدل پیشنهادی با استفاده از زبان برنامه نویسی پایتون^۵ پیاده سازی، اجرا و نتایج عملکرد بطور جداگانه ثبت شد. موازی با LSTM مدل های GARCH(1,1) و GJR-GARCH(1,1,1) همچنین BootStrap TARCH(1,2,0) به صورت جداگانه بررسی، پیاده سازی و ارزیابی شدند.

برای تعیین پارامتر های مدل BootStrap-TARCH سعی شده بهینه ترین حالت پارامتر ها انتخاب شود. شکل زیر مقایسه پارامتر های BootStrap-TARCH را بر اساس شاخص ارزیابی RMSPE روی داده های Validation نشان می دهد.


¹ Evaluation indicator

² Root Mean Squared Error

³ Mean Absolute Percentage Error

⁴ Parameter Determination

⁵ Python



شکل ۷. ارزیابی نتایج تنظیم دقیق^۱ پارامترهای p, q, o برای مدل Bootstrap-TARCH براساس شاخص RMSPE

همچنین برای بدست آوردن بهترین حالت مدل پیشنهادی سعی شده مدل با پارامترهای اصلی مختلفی اعم از تعداد لایه، تعداد نورون های هر لایه، نرخ لایه انصرافی، تابع فعالساز، اندازه دسته، پیاده سازی، مقایسه و ارزیابی شوند.

Model	Main Parameter
Multi-VariateBidirectional-LSTM	Epoch=140; Dropout=0.1; Loss=MSE; N=16/32; Activation=Tanh; Metrics= RMSPE;Batch-size=64;optimizer=adam
GJR-GARCH	$p=1; q=1; o=1$; constant mean , skewed t-distribution
BootStrap-TARCH	$p=1; q=2; o=0$; power=0.1; constant mean , skewed t-distribution
GARCH(1,1)	$p=1; q=1$; constant mean , normal-distribution


جدول ۱. پارامترهای پیکربندی مدل ها

طبق جدول بالا، مدل پیشنهادی دارای دو لایه به ترتیب شامل ۱۶ و ۳۲ نورون در هر لایه یک لایه انصراف برای جلوگیری از بیش برازش میباشد. همچنین از تابع فعالساز \tanh و شاخص ارزیابی حین آموزش RMSPE و تابع خطا MSE استفاده شده است و مدل طی فرایند ۱۴۰ دوره آموزش به همگرایی قابل قبولی می رسد.


¹ Fine-tuning

۵: بحث و نتایج


در ادامه نتایج مدل ها ارایه شده است




شکل ۸. نتیجه مدل Multi-variate Bidirectional 2 Layer LSTM (بخشی از داده آزمایش)



شکل ۹. نتیجه مدل GJR-GARCH(1,1,1) (بخشی از داده آزمایش)



شکل ۱۰. نتیجه مدل Bootstrap-TARCH(1,2,0) (بخشی از داده آزمایش)



شکل ۱۱. نتیجه مدل GARCH(1,1) (بخشی از داده آزمایش)

در جدول زیر نتایج حاصل از پیش بینی بر اساس مقادیر خطای پیش بینی برای مدل‌های مختلف ارائه شده است. مقایسه نتایج بدست آمده نشان می‌دهد که مدل Multi-variate-Bidirect 2 layer LSTM دارای میزان خطای پایین‌تری جهت پیش بینی است، چرا که کلیه معیارهای محاسباتی خطا در این مدل کمتر از سایر مدل‌ها است. حال آنکه برای سایر مدل‌ها، معیارهای ارزیابی خطا مقادیر بالاتری را نشان می‌دهد. بر این اساس می‌توان گفت که مدل Multi-variate-Bidirect 2 layer LSTM توان بالایی را نسبت به سایر مدل‌ها در پیش بینی قیمت بیت کوین دارد.

Model	RMSPE	RMSE	MAPE
MultiVariate-Bidirectional-2Layer	0.351306	0.046480	20.255175
GJR-GARCH(1,1,1)	0.296675	0.067330	23.109112
BootStrap-TARCH(1,2,0)	0.372053	0.062160	26.312609
GARCH(1,1)	0.556840	0.137964	53.473555

۶ : نتیجه گیری

با توجه به نتایج به دست آمده، مدل Multi-Variate-Bidirectional-2layer-LSTM عملکرد بهتری در پیش‌بینی نوسانات دارد.

این نتایج نشان می‌دهد که LSTM می‌تواند به سرمایه‌گذاران بیت‌کوین دقت بیشتری در پیش‌بینی نوسانات قیمت بدهد. با این حال، به دلیل تحول مداوم داده‌های مالی، تنظیم و بروزرسانی مدل‌ها بر اساس اطلاعات جدید امری بسیار حیاتی است تا مدل‌ها قادر به پیش‌بینی با دقت بالا بمانند.

بنابراین به عنوان اصلاحات، مدل‌های پیش‌بینی نیازمند تنظیم مداوم بر اساس آخرین تحولات و اطلاعات موجود هستند تا اطمینان حاصل شود که آن‌ها به روز و آموخته شده با بازارها باقی می‌مانند.

منابع :

صالحی فر . محمد. (1398) بررسی رفتار بازده و ریسک بیت کوین درمقایسه با بازارهای طال، ارز و بورس با رویکرد مدل‌های GARCH-GJR و گارچ آستانه. مهندسی مالی و مدیریت اوراق بهادار

References

Nakamoto, S. (2008). Bitcoin: a peer-to-peer electronic cash system. Decentralized business review.

<https://www.debr.io/article/21260-bitcoin-a-peer-to-peer-electronic-cash-system>

Sovbetov, Y. (2018). Factors influencing cryptocurrency prices: Evidence from bitcoin, ethereum, dash, bitcoin, and monero. Journal of economics and financial analysis, 2(2), 1-27. DOI: 10.1991/jefa.v2i2.a16

Velankar, S., Valecha, S., & Maji, S. (2018, February). Bitcoin price prediction using machine learning. 20th international conference on advanced communication technology (ICACT) (pp. 144-147). IEEE. DOI: 10.23919/ICACT.2018.8323676

Atsalakis, G. S., Atsalaki, I. G., Pasiouras, F., & Zopounidis, C. (2019). Bitcoin price forecasting with neuro-fuzzy techniques. European journal of operational research, 276(2), 770-780.

<https://doi.org/10.1016/j.ejor.2019.01.040>

Guo, T., Bifet, A., & Antulov-Fantulin, N. (2018, November). Bitcoin volatility forecasting with a glimpse into buy and sell orders. 2018 IEEE international conference on data mining (ICDM) (pp. 989-994). IEEE.

Crosby, M., Pattanayak, P., Verma, S., & Kalyanaraman, V. (2016). Blockchain technology: Beyond bitcoin. Applied innovation, 2(6-10), 71. <https://j2-capital.com/wp-content/uploads/2017/11/AIR-2016-Blockchain.pdf>

Jang, H., & Lee, J. (2017). An empirical study on modeling and prediction of bitcoin prices with bayesian neural networks based on blockchain information. IEEE access, 6, 5427-5437. DOI: 10.1109/ACCESS.2017.2779181

Yang, L., Liu, X. Y., Li, X., & Li, Y. (2019, October). Price prediction of cryptocurrency: an empirical study. International conference on smart blockchain (pp. 130-139). Springer, Cham. DOI: 10.1007/978-3-030-34083-4_13

Fischer, T., & Krauss, C. (2018). Deep learning with long short-term memory networks for financial market predictions. European journal of operational research, 270(2), 654-669.
<https://doi.org/10.1016/j.ejor.2017.11.054>

Rashid, T. A., Fattah, P., & Awla, D. K. (2018). Using accuracy measure for improving the training of LSTM with metaheuristic algorithms. Procedia computer science, 140, 324-333.

Wu, T. Q., Yao, M., & Yang, J. H. (2016). Dolphin swarm algorithm. Frontiers of information technology & electronic engineering, 17(8), 717-729. DOI: 10.1631/FITEE.1500287

Qiao, W., & Yang, Z. (2019). Modified dolphin swarm algorithm based on chaotic maps for solving highdimensional function optimization problems. IEEE access, 7, 110472-110486. DOI: 10.1109/ACCESS.2019.2931910

Ewees, A. A., Abd Elaziz, M., Alameer, Z., Ye, H., & Jianhua, Z. (2020). Improving multilayer perceptron neural network using chaotic grasshopper optimization algorithm to forecast iron ore price volatility. Resources policy, 65, 101555. <https://doi.org/10.1016/j.resourpol.2019.101555>

Heidari, A. A., Faris, H., Aljarah, I., & Mirjalili, S. (2019). An efficient hybrid multilayer perceptron neural network with grasshopper optimization. Soft computing, 23(17), 7941-7958.
<https://link.springer.com/article/10.1007/s00500-018-3424-2>

Zhou, C., Yin, K., Cao, Y., & Ahmed, B. (2016). Application of time series analysis and PSO-SVM model in predicting the Bazimen landslide in the three gorges reservoir, China. Engineering geology, 204, 108- 120. DOI: 10.1016/j.enggeo.2016.02.009

Albariqi, R., & Winarko, E. (2020, February). Prediction of bitcoin price change using neural networks. 2020 international conference on smart technology and applications (ICoSTA) (pp. 1-4). IEEE. DOI: 10.1109/ICoSTA48221.2020.1570610936

- Hitam, N. A., Ismail, A. R., & Saeed, F. (2019). An optimized support vector machine (SVM) based on particle swarm optimization (PSO) for cryptocurrency forecasting. *Procedia computer science*, 163, 427-433. DOI: 10.1016/j.procs.2019.12.125
- Kurbucz, M. T. (2019). Predicting the price of bitcoin by the most frequent edges of its transaction network. *Economics letters*, 184, 108655. DOI: 10.1016/j.econlet.2019.108655
- Chen, C. C., Chang, J. H., Lin, F. C., Hung, J. C., Lin, C. S., & Wang, Y. H. (2019, December). Comparison of forecasting ability between backpropagation network and ARIMA in the prediction of bitcoin price. 2019 international symposium on intelligent signal processing and communication systems (ISPACS) (pp. 1-2). IEEE. DOI: 10.1109/ISPACS48206.2019.8986297
- Heo, J. S., Kwon, D. H., Kim, J. B., Han, Y. H., & An, C. H. (2018). Prediction of cryptocurrency price trend using gradient boosting. *KIPS transactions on software and data engineering*, 7(10), 387-396. DOI: 10.3745/KTSDE.2018.7.10.387
- Xiong, L., & Lu, Y. (2017, April). Hybrid ARIMA-BPNN model for time series prediction of the Chinese stock market. 3rd international conference on information management (ICIM) (pp. 93-97). IEEE. DOI: 10.1109/INFOMAN.2017.7950353
- Katsiampa, P. (2017). Volatility estimation for bitcoin: a comparison of GARCH models. *Economics letters*, 158, 3-6. DOI: 10.1016/j.econlet.2017.06.023
- Radityo, A., Munajat, Q., & Budi, I. (2017, October). Prediction of bitcoin exchange rate to American dollar using artificial neural network methods. *International conference on advanced computer science and information systems (ICACSIS)* (pp. 433-438). IEEE. DOI: 10.1109/ICACSIS.2017.8355070
- Sin, E., & Wang, L. (2017, July). Bitcoin price prediction using ensembles of neural networks. 13th international conference on natural computation, fuzzy systems and knowledge discovery (ICNC-FSKD) (pp. 666- 671). IEEE. DOI: 10.1109/FSKD.2017.8393351
- Greaves, A., & Au, B. (2015). Using the bitcoin transaction graph to predict the price of bitcoin. Retrieved from http://snap.stanford.edu/class/cs224w2015/projects_2015/Using_the_Bitcoin_Transaction_Graph_to_Predict_the_Price_of_Bitcoin.pdf

Madan, I., Saluja, S., & Zhao, A. (2015). Automated bitcoin trading via machine learning algorithms. Retrieved from <http://cs229.stanford.edu/proj2014/Isaac%20Madan,%20Shaurya%20Saluja,%20Aojia%20Zhao,Automated%20Bitcoin%20Trading%20via%20Machine%20Learning%20Algorithms.pdf>

Chen, Zh., Li, C., & Sun, W. (2020). Bitcoin price prediction using machine learning: an approach to sample dimension engineering. *Journal of computational and applied mathematics*, 365, 112395. DOI: 10.1016/j.cam.2019.112395

Dutta, A., Kumar, S., & Basu, M. (2020). A gated recurrent unit approach to bitcoin price prediction. *Journal of risk and financial management*, 13(2), 23. DOI: 10.3390/jrfm13020023

Yamak, P. T., Yujian, L., & Gadosey, P. K. (2019, December). A comparison between arima, lstm, and gru for time series forecasting. *Proceedings of the 2nd international conference on algorithms, computing and artificial intelligence* (pp. 49-55). Association for computing machinery. New York, NY, United States. DOI: 10.1145/3377713.3377722